



Universidad Nacional de Ingeniería
Facultad de Ciencias
Escuela Profesional de Ciencia de la Computación

Examen Parcial
Parte Práctica
Minería de Datos

CC442

06/02/2026

Ciclo: 2025-III

Puntaje: 12 puntos

Duración. 100 minutos

PARTE I (2 puntos)

Dado el siguiente conjunto de datos para decidir si comprar un producto:

i	Precio	Calidad	Comprar
1	Alto	Alta	Sí
2	Alto	Baja	No
3	Medio	Alta	Sí
4	Bajo	Alta	Sí
5	Bajo	Baja	No
6	Alto	Alta	No
7	Medio	Baja	No
8	Bajo	Baja	No

Se pide:

- Calcula la entropía inicial del conjunto completo $H(Y)$. (0.3 puntos)
- Calcula la ganancia de información (Information Gain) para ambos atributos: Precio y Calidad. (0.9 puntos)
- ¿Qué atributo elegirías como raíz del árbol y por qué? (0.2 puntos)
- Construye el árbol de decisión completo usando el algoritmo ID3. Muestra todos los nodos internos y hojas. (0.6 puntos)

PARTE II (5 puntos)

CASO: Clasificación de Propietarios de Cortacéspedes

Dataset: *RidingMowers.csv*

Contexto

Una empresa que fabrica cortacéspedes autopropulsados (Riding Mowers) desea identificar a los mejores prospectos de ventas para una campaña de marketing intensiva. En particular, el fabricante está interesado en clasificar los hogares como **propietarios (Owners)** o **no propietarios (Nonowners)** basándose en dos variables predictoras:

1. **Ingresos (Income):** Expresado en miles de dólares (\$1000s).
2. **Tamaño del lote (Lot Size):** Expresado en miles de pies cuadrados (1000 ft²).

El experto en marketing seleccionó una muestra aleatoria de 24 hogares, cuyos datos se encuentran en el archivo *RidingMowers.csv*.

Tareas a realizar

Utilice todos los datos para ajustar un modelo de **regresión logística** donde la variable dependiente es la propiedad (Ownership) y los predictores son el Ingreso y el Tamaño del Lote. Responda lo siguiente:

- a. ¿Qué porcentaje de los hogares del estudio eran propietarios de un cortacésped?
- b. Cree un gráfico de dispersión de *Ingresos* vs. *Tamaño del Lote* utilizando color o símbolos para distinguir a los propietarios de los no propietarios. A partir del gráfico, ¿qué clase parece tener un ingreso promedio más alto?
- c. Entre los que realmente son "no propietarios", ¿cuál es el porcentaje de hogares clasificados correctamente por el modelo (usando un punto de corte de 0.5)?
- d. Si el objetivo es aumentar el porcentaje de "no propietarios" clasificados correctamente, ¿el umbral de probabilidad (cutoff) debería aumentarse o disminuirse?
- e. Calcule los *odds* (posibilidades) de que un hogar con un ingreso de \$60,000 y un tamaño de lote de 20,000 pies cuadrados sea propietario.
- f. ¿Cuál es la clasificación (propietario o no propietario) de un hogar con un ingreso de \$60,000 y un tamaño de lote de 20,000 pies cuadrados, utilizando un punto de corte (cutoff) de 0.5?
- g. ¿Cuál es el ingreso mínimo que debería tener un hogar con un tamaño de lote de 16,000 pies cuadrados para ser clasificado como propietario?

PARTE III (5 puntos)

CASO: Predicción de vuelos retrasados (Boosting)

Dataset: *FlightDelays.csv*

Contexto

El archivo *FlightDelays.csv* contiene información sobre todos los vuelos comerciales que partieron del área de Washington, D.C. (aeropuertos IAD, DCA, BWI) con destino a Nueva York (LGA, JFK, EWR) durante el mes de enero de 2004. Para cada vuelo, se dispone de información sobre los

aeropuertos de origen y destino, la distancia de la ruta, el día de la semana, la aerolínea y la hora programada de salida.

La variable objetivo a predecir es **Flight Status** (Estado del vuelo), la cual indica si un vuelo se retrasó o no. Para este estudio, un retraso se define como una llegada que ocurre al menos 15 minutos tarde respecto a lo programado.

Tareas de Preprocesamiento de Datos

Antes de entrenar el modelo, realice las siguientes transformaciones:

1. **Categorización:** Transforme la variable que contiene el día de la semana (day_week) en una variable de tipo categórico.
2. **Agrupación (Binning):** Divida la hora de salida programada (scheduled departure time) en ocho intervalos o "bins" (en Python, utilice la función `pd.cut()` del paquete pandas).
3. **Partición de Datos:** Divida el conjunto de datos en un set de **entrenamiento (60%)** y un set de **validación (40%)**.

Modelado

Ajuste un modelo de **Árbol de Clasificación con Boosting** (AdaBoost) para predecir los retrasos.

Utilice `n_estimators = 500`.

Establezca `random_state = 1`.

Mantenga la configuración por defecto para el clasificador base (`DecisionTreeClassifier`) y para el `AdaBoostClassifier`.

Preguntas a resolver

- a. En comparación con un árbol de decisión único, ¿cómo se comporta el árbol con Boosting en términos de la **precisión (accuracy) global**?
- b. En comparación con un árbol de decisión único, ¿cómo se comporta el árbol con Boosting en términos de su capacidad para **identificar específicamente los vuelos retrasados**?
- c. Explique detalladamente por qué este modelo (Boosting) podría presentar un mejor rendimiento en comparación con otros modelos de clasificación que haya ajustado previamente para este problema.