



Universidad Nacional de Ingeniería
Facultad de Ciencias
Escuela Profesional de Ciencia de la Computación

Práctica Calificada III

Minería de Datos

CC442

30/01/2026

Ciclo: 2025-III

Puntaje: 20 puntos

Duración: 120 minutos

PARTE I (14 puntos)

CASO: Análisis Predictivo de Diagnóstico Oncológico mediante Regresión Logística

Notebooks: *ejercicio-01.ipynb* y *vif.ipynb*

El conjunto de datos *Breast Cancer Wisconsin (Diagnostic)* es un recurso clásico en el ámbito de la minería de datos y la bioestadística. Contiene características computadas a partir de imágenes digitalizadas de aspiraciones con aguja fina (FNA) de masas mamarias. El objetivo principal es clasificar si un tumor es **Benigno (1)** o **Maligno (0)** basándose en sus propiedades morfológicas.

Desarrollar un modelo de **Regresión Logística** utilizando la librería *statsmodels* para realizar un análisis no solo predictivo, sino también inferencial. Se busca identificar qué variables tienen un impacto significativo en el diagnóstico y asegurar la estabilidad estadística del modelo.

Requerimientos del Código

1. Carga y Selección de Datos:

- Cargar el dataset de cáncer de mama directamente desde *sklearn.datasets*.
- Seleccionar un subconjunto de variables predictoras (por ejemplo: mean radius, mean texture, mean perimeter, mean area, mean smoothness, mean compactness) para evitar la redundancia excesiva de dimensiones.

2. Preprocesamiento y Partición:

- Dividir los datos en conjuntos de **entrenamiento (80%)** y **prueba (20%)** para validar la capacidad de generalización del modelo.
- Aplicar **estandarización (Z-score scaling)** a las variables independientes. *Nota: El escalador debe ajustarse solo con los datos de entrenamiento para evitar la fuga de datos (data leakage).*

3. Diagnóstico de Multicolinealidad:

- Calcular el **Factor de Inflación de la Varianza (VIF)** para cada variable.
- Analizar si existe una correlación excesiva entre los predictores que pueda invalidar la interpretación de los coeficientes.

4. Modelado Estadístico:

- Implementar el modelo de Regresión Logística utilizando la clase *Logit* de *statsmodels*.

- Asegurarse de incluir manualmente el **término de intercepto (constante)**.
 - Generar y mostrar el resumen estadístico (summary) del modelo.
5. **Evaluación e Interpretación:**
- Realizar predicciones sobre el conjunto de prueba utilizando un umbral de decisión de **0.5**.
 - Generar un reporte de clasificación (precisión, recall, F1-score) y una matriz de confusión.
 - Calcular e interpretar los **Odds Ratios** (exponencial de los coeficientes) para cuantificar el cambio en la probabilidad de diagnóstico por cada unidad de cambio en los predictores.

Preguntas de Reflexión (Análisis de Resultados)

- ¿Cuáles variables resultaron ser estadísticamente significativas (p-valor < 0.05)?
- ¿Qué indica un VIF elevado en variables como el radio y el perímetro?
- ¿Cómo afecta el signo de los coeficientes a la probabilidad de que el tumor sea clasificado como benigno?

Salida esperada:

```

--- Diagnóstico VIF ---
      Variable      VIF
0      const      1.000000
1  mean radius 1460.924793
2  mean texture   1.144166
3  mean perimeter 1737.092968
4      mean area   44.049377
5  mean smoothness  2.064559
6  mean compactness 11.866719
-----
Optimization terminated successfully.
      Current function value: 0.159583
      Iterations 10

      Logit Regression Results
=====
Dep. Variable:          target    No. Observations:          455
Model:                Logit      DF Residuals:            448
Method:                MLE       DF Model:                6
Date:                 Thu, 29 Jan 2026    Pseudo R-squ.:          0.7581
Time:                 19:33:50    Log-Likelihood:         -72.610
converged:              True      LL-Null:                -300.17
Covariance Type:       nonrobust    LLR p-value:            3.887e-95
=====

```

	coef	std err	z	P> z	[0.025	0.975]
const	-0.2118	0.513	-0.413	0.680	-1.218	0.794
mean radius	22.6977	11.506	1.973	0.049	0.146	45.249
mean texture	-1.5228	0.270	-5.650	0.000	-2.051	-0.995
mean perimeter	-16.9089	11.079	-1.526	0.127	-38.624	4.806
mean area	-12.6785	5.118	-2.477	0.013	-22.709	-2.648
mean smoothness	-1.6515	0.359	-4.599	0.000	-2.355	-0.948
mean compactness	0.2827	0.817	0.346	0.729	-1.319	1.885

```

=====

```

Possibly complete quasi-separation: A fraction 0.15 of observations can be perfectly predicted. This might indicate that there is complete quasi-separation. In this case some parameters will not be identified.

--- Reporte de Clasificación (Scikit-Learn Metrics) ---

	precision	recall	f1-score	support
0	0.93	0.91	0.92	43
1	0.94	0.96	0.95	71
accuracy			0.94	114
macro avg	0.94	0.93	0.93	114
weighted avg	0.94	0.94	0.94	114

--- Odds Ratios (Interpretación) ---

const	8.091427e-01
mean radius	7.202470e+09
mean texture	2.180995e-01
mean perimeter	4.534986e-08
mean area	3.117395e-06
mean smoothness	1.917570e-01
mean compactness	1.326692e+00
dtype:	float64

PARTE II (6 puntos)

Completar códigos.

Notebook: *ejercicio-02.ipynb*